



Actividad 8

Materia:	<i>Gestión de proyectos de inteligencia artificial</i>
Actividad:	<i>Actividad 8.</i>
Alumno(a):	<i>Carmen Elizabeth Juárez Mortera</i>
Matrícula:	<i>AL02988119</i>
Docente:	<i>M. en C. Luis Ariel Vázquez Piña.</i>
Fecha de entrega:	<i>19/07/2026</i>

Desarrollo de Contenido

Objetivo: Implementar la monitorización, mantenimiento y gobernanza operativa, asegurando la continuidad y confiabilidad del servicio. Al finalizar, deberás proporcionar evidencia documentada de cada fase del proceso, incluyendo el uso adecuado de herramientas y la simulación de incidentes críticos.

1. Definición de indicadores (métricas, logs, trazas)

Para monitorear el comportamiento de la API desarrollada en la fase anterior con FastAPI y del modelo de regresión lineal, se definieron indicadores de observabilidad moderna basados no solo en métricas, sino que también incluye registros de eventos y trazas operativas. Estos indicadores permiten conocer el estado general del servicio, detectar incumplimientos de los objetivos de nivel de servicio (SLO) y analizar incidentes.

Las métricas registradas son las siguientes:

Métrica	Descripción
Latencia	Tiempo empleado por la API para procesar una solicitud y devolver una respuesta.
Predicción generada	Número de días estimados por el modelo para desarrollar un módulo de software.
Código HTTP	Resultado de la solicitud procesada por la API
Total de predicciones	Cantidad de predicciones registradas por el servicio
Total de alertas	Número de incumplimientos o incidentes detectados
Total de errores	Cantidad de errores internos registrados
Cumplimiento de SLO	Porcentaje de evaluaciones que cumplen los objetivos definidos.

Para el registro de las métricas y eventos relevantes como:

- Predicciones generadas;
- Métricas sli;
- Evaluación de slo;
- Alertas;
- Incidentes simulados;
- Errores internos.

Se utiliza el archivo log.

Clasificación de los niveles de log utilizados

Nivel	Uso
INFO	Operaciones normales, métricas y evaluaciones.
WARNING	Incumplimientos de SLO e incidentes no críticos
ERROR	Fallos internos e incumplimiento de disponibilidad

Cada petición al sistema genera una secuencia de eventos que permite reconstruirlo.

- Solicitud recibida
 - a. Datos de entrada
 - b. Predicción
 - c. Métricas SLI
 - d. Evaluación de SLO
 - e. Generación de alerta si aplica

2. Diseño de alertas inteligentes

El sistema de alertas esta basado en el cumplimiento de los Objetivos de Nivel de Servicio (SLO), es decir, que las alertas se generan cuando un indicador de nivel de servicio incumple el objetivo establecido, evitando la fatiga en las alertas.

Para el monitoreo de la API se definieron tres SLO principales:

LATENCIA: El 95% de las solicitudes deben responder en menos de 500 ms.

DISPONIBILIDAD: Al menos el 99% de las solicitudes deben responder con código HTTP 200.

CALIDAD: El 100% de las predicciones deben ser válidas (mayores que cero)

Por lo tanto, con base en los niveles esperados de desempeño del servicio, el sistema genera tres tipos de alertas:

Alerta por incumplimiento de latencia

Se activa cuando la evaluación del SLO determina que el tiempo de respuesta supera el objetivo establecido.

Tipo de alerta

WARNING

Alerta por incumplimiento de calidad

Se produce cuando el resultado de la predicción no cumple con las condiciones definidas para una salida válida del modelo.

Tipo de alerta

WARNING

Alerta por incumplimiento de disponibilidad

Se genera cuando la API devuelve un código HTTP diferente a 200, indicando que la solicitud no pudo procesarse correctamente.

Tipo de alerta

ERROR

Con base en lo anterior, y al impacto que generan al usuario se clasificaron las alertas de acuerdo con la siguiente tabla:

Prioridad	Tipo de incidente	Impacto
Alta	Disponibilidad	La API deja de prestar el servicio al usuario.
Media	Latencia	El servicio continúa disponible, pero el tiempo de respuesta supera el objetivo definido.
Media	Calidad	La API responde pero la predicción generada no cumple con los criterios establecidos.

La tolerancia a cada riesgo se estableció a partir del error Budget asociado a cada SLO.

Indicador	SLO	Presupuesto de error
Latencia	95 %	Se permite que hasta el 5 % de las solicitudes excedan los 500 ms.
Disponibilidad	99 %	Se acepta hasta un 1 % de respuestas con error.
Calidad	100 %	No se aceptan predicciones inválidas.

3. Descripción de dashboards

Se desarrolló un dashboard para visualizar en tiempo real el estado de la API, el comportamiento del modelo y el cumplimiento de los SLO, utilizando Streamlit.

La fuente pertenece al archivo de registros api.log, donde se guardan las métricas, eventos y alertas generadas por el sistema.

La jerarquía de visualización del dashboard corresponde al:

Estado general del servicio donde se encuentran los KPIs principales.

Cumplimiento de los SLO con un esquema de colores para validar objetivo cumplido u objetivo incumplido.

Gráficas de monitoreo que muestran tendencias de las principales métricas registradas para identificar variaciones en el desempeño y analizar el comportamiento del modelo durante la operación.

Historial de alertas que muestra los últimos eventos registrados con fecha y hora del evento, tipo de alerta, nivel de severidad y descripción del incidente.

4. Runbooks de respuesta a incidentes

Runbook para incidente de disponibilidad:

Identificador: SLO_DISPONIBILIDAD_INCUMPLIDO

Descripción: Este incidente ocurre cuando la API genera un error interno y devuelve un código HTTP diferente de 200.

Acciones de respuesta

- a) Identificar el mensaje de error registrado en el archivo de logs.
- b) Revisar el origen de la excepción generada por la aplicación.
- c) Verificar la disponibilidad del modelo de Machine Learning.
- d) Reiniciar la aplicación si el error persiste.
- e) Confirmar que las solicitudes posteriores respondan correctamente con HTTP 200.

Resultado esperado:

LA API vuelve a responder correctamente y se restablece el cumplimiento de objetivo de nivel de servicio de disponibilidad.

Runbook para incidente de calidad:

Identificador: SLO_CALIDAD_INCUMPLIDO

Descripción: Este incidente ocurre cuando el modelo genera una predicción que no cumple con los criterios establecidos para una solida válida.

Acciones de respuesta

- a) Revisar los valores enviados en la solicitud.
- b) Verificar que las variables de entrada se encuentren dentro de los rangos esperados.
- c) Confirmar que el modelo cargado corresponda a la versión correcta.

- d) Validar que la predicción obtenida sea consistente con los datos de entrada.
- e) Registrar el incidente para su análisis posterior.

Resultado esperado:

Las siguientes predicciones generadas cumplen nuevamente los criterios definidos para el modelo.

Runbook para incidente de latencia elevada

Identificador: SLO_LATENCIA_INCUMPLIDO

Descripción: Este incidente ocurre cuando el tiempo de respuesta de la API supera el límite establecido en el SLO de latencia (500ms)

Acciones de respuesta

- a) Verificar la alerta registrada en el archivo de logs.
- b) Revisar la latencia reportada por el dashboard.
- c) Confirmar si el incremento fue provocado por una simulación de incidente o por una condición real.
- d) Analizar el consumo de recursos del servidor o la carga de trabajo.
- e) Verificar que las solicitudes posteriores vuelvan a cumplir el SLO establecido.

Resultado esperado:

El servicio continúa disponible para el usuario y la latencia retorna a valores inferiores a 500ms.

5. Estrategias de detección de data drift

Cuando los datos utilizados durante la operación difieren significativamente de los empleados durante el entrenamiento, esto puede provocar una disminución en la precisión y confianza en las predicciones.

Para detectar cambios relevantes en la distribución de los datos de entrada y preservar el rendimiento del modelo, se propone comparar periódicamente las características de ambos conjuntos de datos: los utilizados por el modelo durante la operación y las características del conjunto de datos empleado en el entrenamiento.

Las variables monitoreadas corresponden a las utilizadas por el modelo de regresión lineal:

- Número de interfaces de usuario.
- Número de funcionalidades backend.
- Nivel de complejidad.
- Horas disponibles por día.

Los indicadores estadísticos sugeridos para el análisis de cada variable son: promedio; valor mínimo, valor máximo, desviación estándar, distribución de frecuencias. La comparación de estadísticas permite identificar si existe diferencia significativa para alertar oportunamente de posibles cambios que puedan comprometer el desempeño del modelo.

En caso de detectar que existe una desviación significativa se propone el siguiente flujo de acción con el fin de mantener la calidad de las predicciones:

- a) Registrar el evento en el archivo de logs.
- b) Generar una alerta para el responsable del sistema.
- c) Analizar las variables que presentan mayor variación.
- d) Evaluar nuevamente el desempeño del modelo utilizando datos recientes.
- e) Determinar si es necesario reentrenar el modelo con un conjunto de datos actualizado.

En la implementación actual la detección automática de data drift no forma parte de las funcionalidades desarrolladas, sin embargo, constituye una propuesta de mejora que permita ampliar las capacidades de monitoreo del sistema y fortalecer su mantenimiento a largo plazo.

6. Documentación de respuesta automatizada:

La respuesta automatizada desarrollada incluye las siguientes actividades:

Registro automático de eventos

Cada vez que se ejecuta la API el sistema registra automáticamente información relacionada con el funcionamiento del sistema; que se almacena en el archivo de registros api.log.

Evaluación automática de SLO

Después de cada predicción, el sistema evalúa automáticamente los objetivos de nivel de servicio definidos para la aplicación. Y constituye la base para la generación de alertas inteligentes.

Los indicadores son:

- Latencia de respuesta
- Disponibilidad del servicio
- Calidad de la predicción

Generación automática de alertas

Cuando alguno de los SLO definidos no se cumple, la aplicación automática genera la alerta correspondiente.

Estos son:

Alerta	Disparador
SLO_LATENCIA_INCUMPLIDO	Tiempo de respuesta superior a 500 ms.
SLO_DISPONIBILIDAD_INCUMPLIDO	Código HTTP diferente de 200.
SLO_CALIDAD_INCUMPLIDO	Predicción inválida (menor o igual a cero).

Cada alerta queda registrada y posteriormente puede visualizarse en el dashboard operativo.

Visualización automática en el dashboard

El dashboard analiza continuamente el archivo de registros y actualiza la información mostrada al usuario.

Estructura del dashboard:

- Indicadores de estado de servicio

- Métricas de operación
- Cumplimiento de los SLO
- Historial de predicciones
- Historial de alertas

Se proponen mecanismos de respuestas automatizada como: rollback automático del modelo de aplicación, para restaurar a una versión previamente validada cuando se identifique una degradación significativa el desempeño del modelo.

Asimismo, el reentrenamiento automático ante la detección de data drift o una disminución constante en la calidad de las predicciones. Como ultima mejora, se propone integrar servicios de email o mensajería para informar inmediatamente sobre incidentes críticos.

Conclusiones

El proyecto muestra un caso de uso de monitoreo proactivo y respuesta automatizada basada en el registro de eventos, la evaluación automática de los SLO y la generación de alertas inteligentes. La evidencia del desarrollo e implementación del sistema se encuentra en el repositorio de GitHub del proyecto. En dicho repositorio se incluye el código fuente de la API desarrollada con FastAPI, el modelo de Machine Learning, los componentes de monitoreo, el sistema de alertas inteligentes, el dashboard operativo desarrollado con Streamlit, la contenerización mediante Docker y la documentación correspondiente.